Evaluasi, Bias & Interpretabilitas pada LLM

Topics on NLP & LLM
- ADDI Laboratory -

Rarasmaya Indraswari
(WA) 081331818454
raras@its.ac.id

Contents

- Evaluasi Model LLM
- Bias & Fairness dalam LLM
- Interpretabilitas Model LLM

Evaluasi Model LLM

Evaluasi Model LLM

- Jenis evaluasi:
  - Intrinsic: mengukur langsung kualitas model bahasa (misal perplexity).
  - Extrinsic: mengukur performa pada tugas nyata (QA, summarization).
- Metrik evaluasi:

Jenis	Metrik	Deskripsi
Language modeling	Perplexity	Mengukur seberapa baik model memprediksi teks.
Translation	BLEU, METEOR	Perbandingan n-gram dengan referensi.
Summarization	ROUGE, BERTScore	Perbandingan overlap atau embedding-based.
QA/Classification	Accuracy, F1	Standar untuk prediksi kelas.
LLM Benchmark	MMLU, TruthfulQA, HellaSwag	Mengukur reasoning, factuality, dan moral consistency.

Perplexity

- Perplexity (PPL) mengukur seberapa bingung (confused) model dalam memprediksi kata berikutnya.
- Perplexity menilai *kemampuan model memprediksi distribusi kata berikutnya secara akurat.*
- Semakin kecil nilai perplexity, semakin baik modelnya; artinya model lebih yakin terhadap prediksinya.
- Rumus:

$$PPL = e^{-\frac{1}{N}\sum_{i=1}^{N}\log P(w_i)}$$

N: jumlah kata dalam kalimat

$P(w_i)$: probabilitas kata ke-i menurut model

BLEU (Bilingual Evaluation Understudy)

- Digunakan terutama untuk evaluasi hasil terjemahan atau text generation.
- Mengukur kesamaan antara teks hasil model dan teks referensi (ground truth) dengan menghitung overlap *n-gram*.
- Rumus:

$$BLEU = BP \times \exp\left(\sum_{n=1}^{N} w_n \log p_n\right)$$

p_n: precision untuk n-gram (1-gram, 2-gram, dst)

BP: brevity penalty (hukuman untuk kalimat terlalu pendek)

ROUGE (Recall-Oriented Understudy for Gisting Evaluation)

- Umumnya digunakan untuk evaluasi summarization (perangkuman teks).
- Fokus pada recall: seberapa banyak informasi dari referensi yang berhasil ditangkap oleh model.
- Jenis:
  - ROUGE-N: overlap n-gram
  - ROUGE-L: longest common subsequence
  - ROUGE-S: skip-bigram overlap

BERTScore

- Diciptakan karena BLEU/ROUGE hanya mengukur kesamaan kata, bukan makna.
- BERTScore membandingkan kesamaan semantik antar token menggunakan embedding dari model BERT.
- Mekanisme:
  - Ubah teks referensi dan hasil model menjadi embedding (dari BERT).
  - Hitung cosine similarity antar token.
  - Ambil nilai rata-rata.
- Contoh:
  - Referensi: “The car is fast.”
  - Prediksi: “The automobile is quick.”
  - Secara makna sama, meski tidak ada kata yang sama.
  - BLEU/ROUGE rendah, tapi BERTScore tinggi.

MMLU (Massive Multitask Language Understanding)

- Evaluasi kemampuan pengetahuan dan penalaran umum model bahasa (LLM).
- Multi-domain QA yang berisi lebih dari 57 bidang ilmu: sejarah, kimia, hukum, matematika, dll.
- Bentuk tes:
  - Multiple choice (seperti ujian manusia).
  - Contoh, Q: What is the capital of France? A) Berlin B) Paris C) Madrid D) Rome
  - Model memilih jawaban dengan probabilitas tertinggi.
- Skor MMLU = Persentase jawaban benar.
  - Model seperti GPT-4 >80%, sedangkan BERT-base <50%.

Bias & Fairness

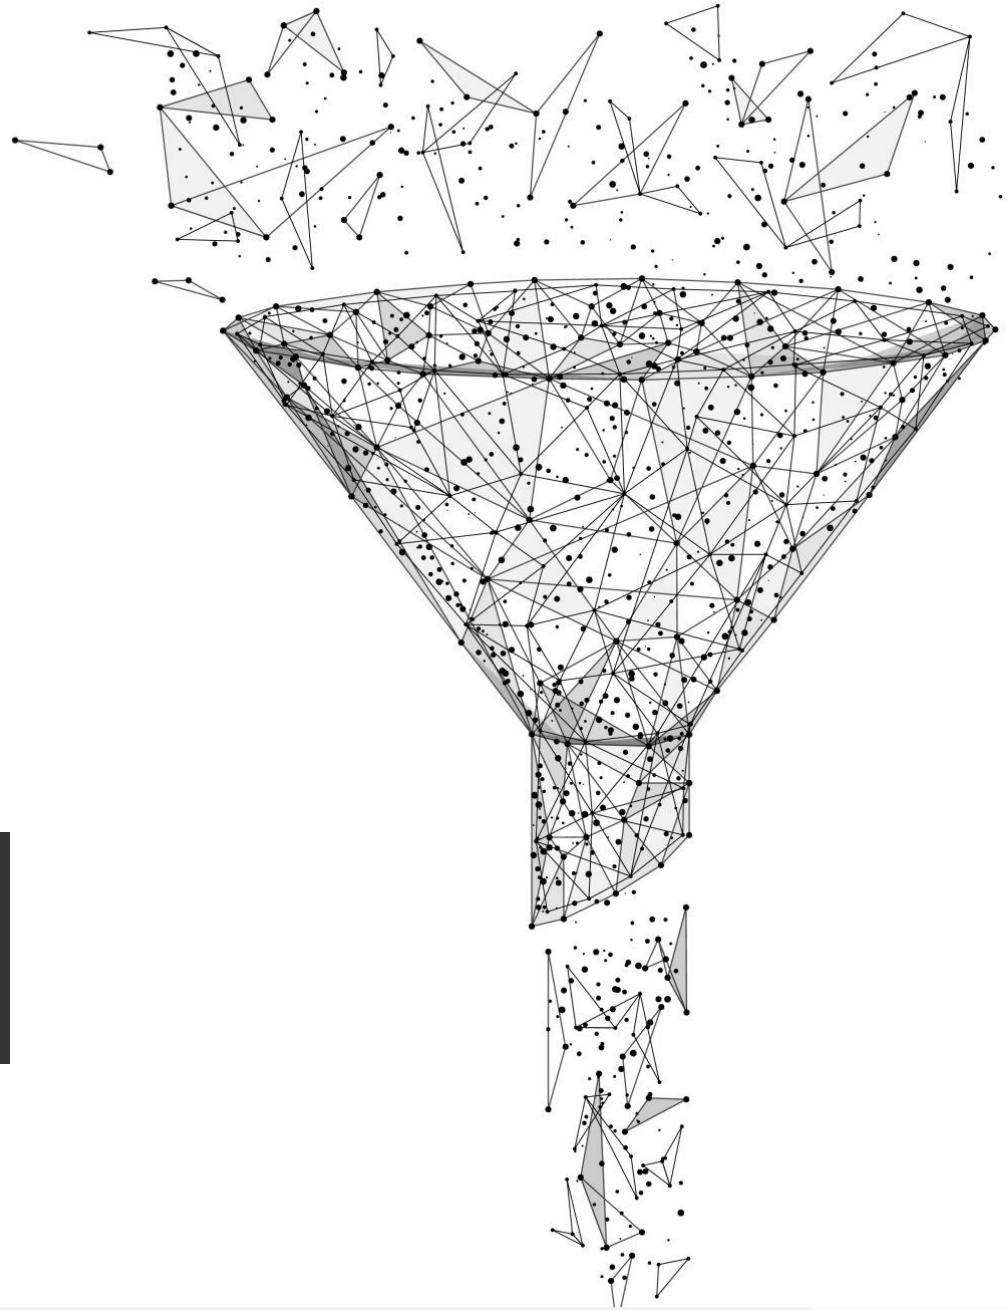

Bentuk Bias

- **Gender bias:** asosiasi peran sosial (nurse–she, doctor–he).
- **Cultural bias:** standar nilai budaya barat mendominasi dataset.
- **Political bias:** arah opini pada model generatif.
- Dll.

Cara Mitigasi

- **Data-level**: filtering, balancing, augmentation.
- **Model-level**: debiasing embedding, adversarial training.
- **Post-hoc**: RLHF, Constitutional AI, red-teaming.

Interpretabilitas Model LLM

Pendekatan

Pendekatan	Contoh	Tujuan
Attention visualization	ExBERT, BertViz	Melihat token mana yang paling diperhatikan.
Feature attribution	Captum, SHAP	Menilai kontribusi tiap fitur/token.
Probing tasks	syntactic probes	Melihat apakah neuron “menyimpan” struktur bahasa.

Tools

- ExBERT: https://exbert.net
- Captum (PyTorch): https://captum.ai
- Google LIT: https://pair-code.github.io/lit/

Thank You